


# Paper Review



필수 reference 논문 리뷰

# ECG(electrocardiogram)




- P : 동방결절에서 전류 신호가 발생하고, 이것이 심방을 극성화 시키면서 판막의 심근이 수축
- P-Q : 전류 신호가 심장을 자극하지 않는 휴지기
- QRS Complex : 방실 결절이 전류신호를 놓아주면(Q), 심실이 즉시 극성화되었다(R)가 곧바로 비극성화(S)
- S-T : S와 T의 사이이며 전류 신호가 심장을 자극하지 않는 휴지기
- T : 심실이 다시 약하게 극성화 되었다가 다시 비극성화 되면서 심실과 심실 판막의 심근이 동시에 이완

- ✓ 심장의 위치, 크기 및 전기 생리학적 요인 등에 의해 개인 고유의 특성을 가져 개인 간의 구별이 뚜렷함
- ✓ 위변조가 어렵기 때문에 보안 측면에서도 강점을 가짐
- ✓ 살아있는 모든 사람에게서 측정이 가능하며 시간이 많이 지나도 심전도의 파형이 크게 변하지 않아 등록을 자주 해주지 않아도 됨

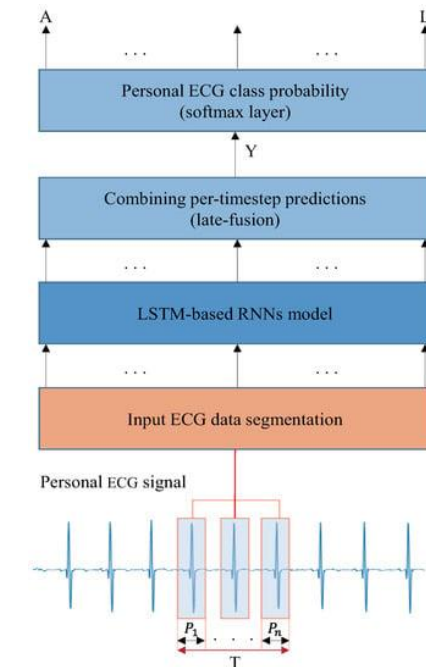
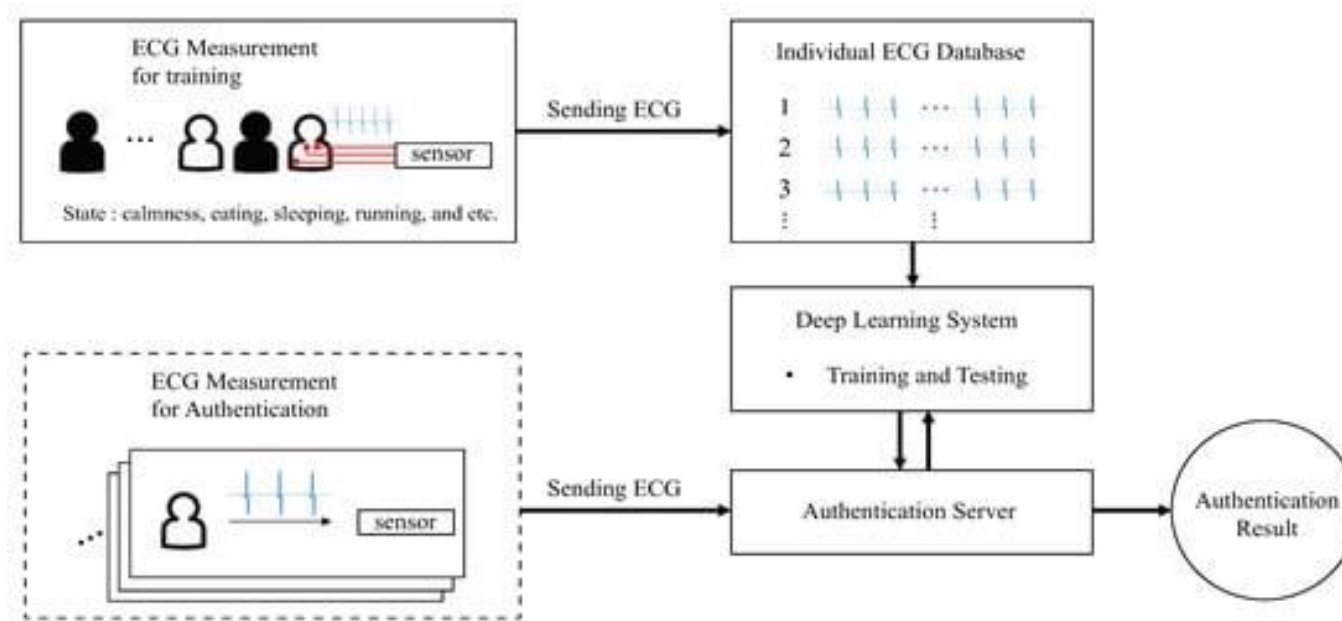
## ECG Identification For Personal Authentication Using LSTM-Based Deep Recurrent Neural Networks

- 최근 지문, 얼굴 인식, 음성 인식 및 심전도(ECG)와 같은 생체 인식 시스템에서 다양한 기본 방법을 포함하는 여러 연구가 수행
  - 지문 및 얼굴 인식 시스템은 지문 위조, 빛, 머리카락, 유리 등의 환경적 장애물과 같은 많은 단점 존재
  - 음성 인식 시스템은 일반적으로 조명을 끄거나 켜거나, 전화를 걸거나, TV 채널을 변경하는 것과 같은 간단한 작업을 수행하는데 사용
  - 위조 또는 위장 식별 문제를 해결하기 위해 이 백서에 나와 있는 것처럼 ECG와 같은 다양한 접근 방식을 고려해야함



## ECG Identification For Personal Authentication Using LSTM-Based Deep Recurrent Neural Networks

- 특징 추출, 시간 주기로 분할, R-피크 감지를 사용한 분할, 짧은 길이의 ECG 신호 그룹화를 포함한 전처리
  - MIT-BIH Normal Sinus Rhythm(NSRDB) MIT-BIH Arrhythmia (MITDB) 데이터 사용
  - ECG 기록을 신호 구성 요소 중 P 주기로 분할하여 사용



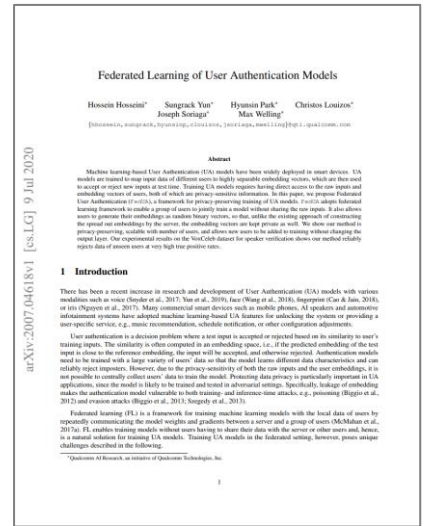
## ECG Identification For Personal Authentication Using LSTM-Based Deep Recurrent Neural Networks

- ECG 분류를 위한 새로운 LSTM 기반 DRNN 아키텍처 사용
  - 입력 시퀀스 길이에 따른 식별 정확도 영향을 평가함
  - 제안된 모델은 최신 방법에 비해 시퀀스가 더 짧을 때 더 나은 성능을 보임
  - 빠른 결과가 필요한 실시간 개인 ECG 식별 시스템에 유용
  - 제안된 LSTM 기반 모델이 기존의 RNN 모델 보다 더 나은 성능을 보임
- Depth, Number of hidden layer, data length를 조정하며 실험
  - NSRDB : 정밀도 100%, 재현율 100%, 정확도 100%, F1-score 1
  - MITDB : 정밀도 99.8%, 재현율 99.8% , 정확도 99.8%, F1-score 0.99

Methods	Dataset	Input Sequence Length (Number of Beats)	Overall Accuracy (%)
Proposed model	MITDB	3	99.73
		9	99.80
H. M. Lynn et al. [15]	MITDB	3	97.60
		9	98.40
R. Salloum et al. [26]	MITDB	3	98.20
		9	100
Q. Zhang et al. [19]	MITDB	1	91.10
X. Zhang [49]	MITDB	8	97.80
		12	98.9
Ö. Yildirim [50]	MITDB	5	99.39

## Federated Learning of User Authentication Models

- 사용자 인증 모델의 개인정보 보호를 위한 연합학습 제안
  - 공유하지 않고 모델을 공동으로 훈련할 수 있는 학습 프레임 워크로 임베딩 벡터 또한 비공개로 진행
  - 개인정보 보호, 사용자 수에 따른 확장 가능, 새 사용자 추가 가능한 이점이 있음
  - VoxCeleb 데이터 세트(Nagrani et al., 2017) 사용하여 실험 진행  
(화자 식별을 위한 대규모 음성파일 데이터 셋)
- 각각 원시 입력 및 임베딩 벡터의 개인 정보를 보호하기 위해 연합 학습 및 랜덤 이진 임베딩 사용
- 사용자 수에 따라 확장 가능하며 일반적으로 FL 설정에서 수행되는 통신을 제외하고 사용자 간 또는 사용자와 서버 간의 조정이 필요하지 않음을 증명



### Federated Learning of User Authentication Models

- 다양한 데이터 특성을 학습하고 사용자를 안정적으로 인증할 수 있도록 인증 모델은 다양한 사용자 데이터로 학습되어야 함
  - 화자 인식 모델은 높은 정확도로 사기꾼을 거부할 수 있도록 다양한 연령, 성별, 억양 등을 가진 사용자의 음성 데이터 학습이 필요
- 데이터 개인 정보 보호는 모델이 적대적인 환경에서 훈련되고 테스트될 가능성이 있는 UA(User Authentication) 애플리케이션에서 특히 중요
  - 원시 입력과 임베딩 벡터 모두 민감한 정보로 간주되어 공격에 취약해짐
  - 따라서, 임베딩 벡터도 비공개로 유지

### Federated Learning of User Authentication Models

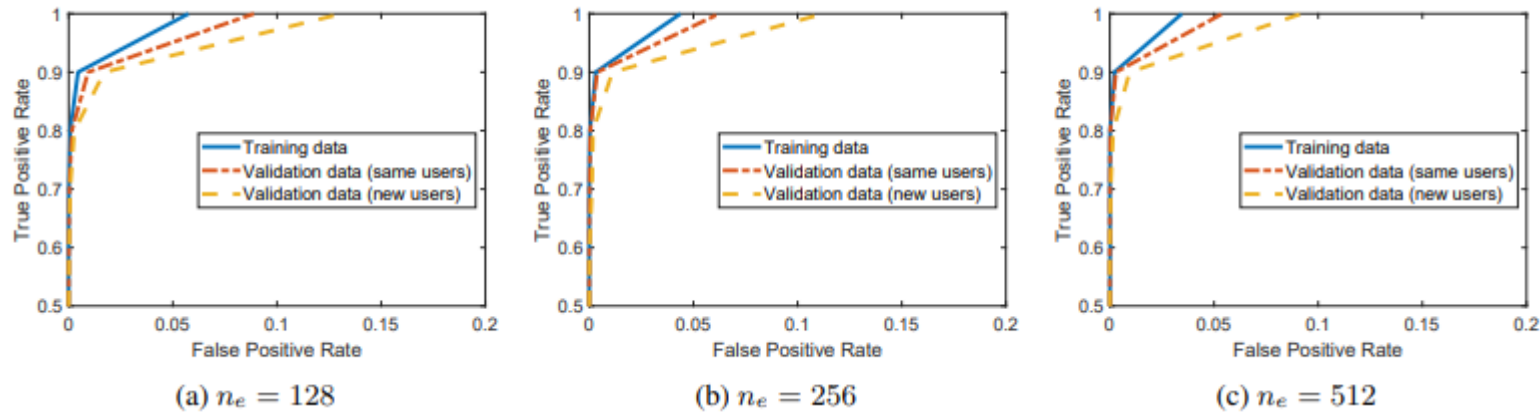
- FL의 단점
  - 사용자의 임베딩 벡터는 미리 정의되지 않음
  - 모델 가중치와 기울기는 서버와 사용자 간에 여러 번 통신해야 함
  - 훈련 및 추론은 일반적으로 리소스가 제한된 로컬 장치에서 수행됨

⇒ UA 모델 학습을 위한 FL 프레임워크를 채택

- 사용자는 훈련 전에 생성된 임의의 임베딩 벡터로 모델을 훈련
- 개인 정보를 보호하고 임베딩 벡터 간에 높은 수준의 분리성을 제공




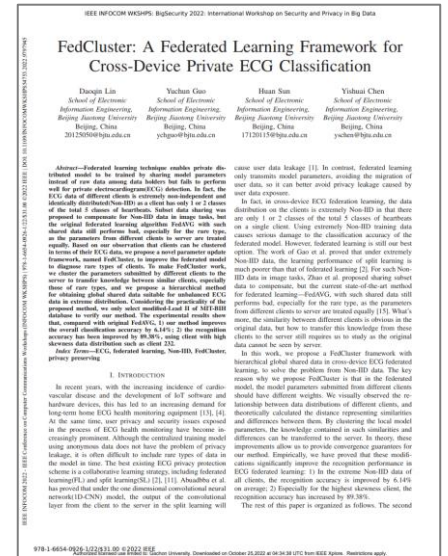
### Federated Learning of User Authentication Models



- 모든 경우에 매우 낮은 FPR(False Positive Rate)에서 높은 TPR(True Positive Rate)을 달성
- TPR=80%에서  $n_e$ (임베딩 벡터 길이) = 128, 256 및 512에 대해 신규 사용자 데이터에서 FPR=0.27%, 0.18%, 0.16% 달성
  - 화자 검증 데이터 세트에 대한 실험 결과는 제안된 방법이 매우 높은 TPR로 보이지 않는 사용자의 데이터를 안정적으로 거부함을 보여줌

## FedCluster: A Federated Learning Framework for Cross-Device Private ECG Classification

- 계층적 글로벌 공유 데이터틀 사용하는 연합 메커니즘 Fedcluster를 제안
  - 연합학습으로 모델 매개변수만 전송하여 사용자 데이터 노출로 인한 개인정보 유출 위험 감소
  - MIT BIH Arrhythmia database 사용하여 총 5개 (N,S,V,F,Q) 클래스로 분류
  - 1D CNN 분류 모델 사용
- 각 클라이언트가 로컬 데이터에 대한 교육을 마친 후 모델 매개변수가 차등 방식으로 서버에 전송
  - 서버는 먼저 수신된 모델 매개변수를 클러스터링 하여 모델 매개변수의 업데이트된 결과를 클래스 내에서 먼저 평균화한 다음 클래스 간 평균화
  - 매개변수의 차이 값만 전송되므로 통신 효율성을 크게 향상



## FedCluster: A Federated Learning Framework for Cross-Device Private ECG Classification

### Algorithm 1 FedCluster

**Input:** ECG data  $x$  & initial model parameters  $w_t$ .

**Output:** Updated model parameters  $w_{t+1}$ .

**Server:**

- 1: send  $w_t$  to each client.
- 2: receive differential parameters of all clients:  
 $(diff_1, diff_2, \dots, diff_n)$
- 3: Using kmeans to cluster differential parameters of all clients:

$$diff_{i,C_k} = F_1(diff_1, diff_2, \dots, diff_n)$$

where,  $i$  denotes the client index, and function  $F_1$  denotes kmeans function.

- 4: update model parameters:

$$w_{t+1} = \frac{\sum_k diff_{i,C_k}}{L(C_k) * K}$$

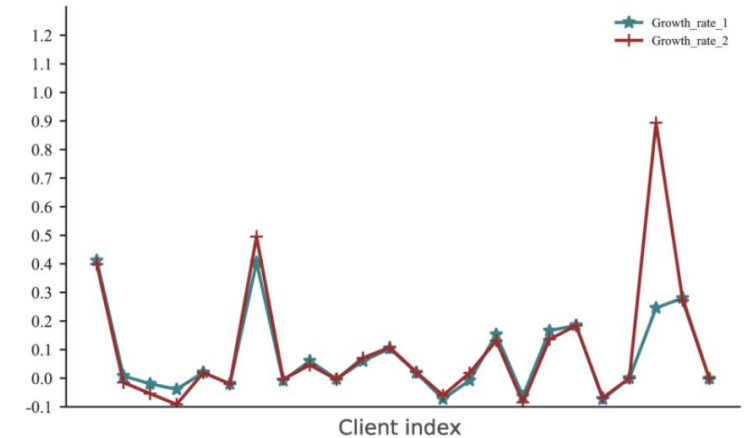


where,  $L(C_k)$  represents that the number of clients belong to type  $k$ ,  $K$  denotes the total number of all types.

**Client  $i$ :**

- 1: initialize the model.
- 2: load model parameters  $w_t$ .
- 3: train model to update parameters:  $w_{t+1}$
- 4: send  $diff_i$  to server:  $diff_i = w_{t+1}^i - w_t$

1. 각 클라이언트에 초기모델 매개변수 전달
  2. 모든 클라이언트의 매개변수 수신
  3. K-means를 사용하여 모든 클라이언트의 매개변수 Clustering
  4. 모델 매개변수 업데이트
- 서로 다른 클라이언트의 데이터 분포 사이의 관계를 시각적 관찰 및 유사점과 차이점을 나타내는 거리를 이론적으로 계산
  - 글로벌 공유 데이터를 생성하는 계층적 방법을 제안
  - 각 클라이언트에 대해 서버에 다른 가중치를 제공하기 위해 새로운 프레임워크인 FedCluster를 제안

## FedCluster: A Federated Learning Framework for Cross-Device Private ECG Classification



- FedCluster 프레임워크를 채택한 후 FedAVG와 비교하여 모든 클라이언트의 전체 인식 정확도가 89.09%에서 89.26%로 향상
  - 왜도가 높은 클라이언트의 경우 분류 정확도가 52% 크게 향상
- Convolutional Layer와 2개의 Full Connected Layer로 구성된 모델을 이용하여 정확도 96.94% 달성

감사합니다

Email: najin2445@gachon.ac.kr